



AWD COURSE

Pemrograman & Analisis Data

MODUL BAB 3

Analisis Data Eksploratif (EDA) dengan Python

Panduan komprehensif inspeksi struktur data (head, tail, info), kalkulasi statistik deskriptif mean/median/std, visualisasi distribusi histogram dan scatter plot, serta teknik seleksi data dan boolean indexing.

KATEGORI

Python & Data Science

FORMAT DOKUMEN

PDF

TINGKAT

Pemula s/d Menengah

AKSES ONLINE

course.awd.my.id

PEMATERI

I Putu Agus Wahyu Dupayana

AWD Course

Pembaruan: **September 2026**

Bab 3: Analisis Data Eksploratif (EDA)

Awd Course – Buku Modul Praktik Komprehensif

Notebook kompilasi lengkap untuk Bab 3 yang mencakup Inspeksi Struktur Dataframe, Statistik Deskriptif, Visualisasi Distribusi, dan Seleksi Data Boolean.

Persiapan & Inspeksi Awal Struktur Dataframe

Analisis Data Eksploratif (Exploratory Data Analysis – EDA) adalah tahapan kritis pertama dalam sains data untuk memahami bentuk fisik data, tipe data setiap variabel, anomali, dan kualitas data sebelum melakukan pemodelan statistik.

1. Menyiapkan & Memuat Dataset Wilayah

PYTHON 3

Contoh Kode Praktik

```
import pandas as pd
import numpy as np

# Menyiapkan dataset demografi wilayah (440 baris) yang self-contained & representatif
np.random.seed(42)
n_samples = 440

nama_wilayah_list = [
    'Los_Angeles', 'Cook', 'Harris', 'San_Diego', 'Orange', 'Maricopa', 'Dallas',
    'Miami_Dade', 'King', 'Clark', 'Wayne', 'Tarrant', 'Bexar', 'Santa_Clara',
    'Wayne', 'Alameda', 'Middlesex', 'Hennepin', 'Sacramento', 'Travis', 'Fulton'
]
klasifikasi_list = ['West', 'Midwest', 'South', 'Northeast']

df = pd.DataFrame({
    'Nomor Identitas Wilayah': np.arange(1, n_samples + 1),
    'Nama Wilayah': [nama_wilayah_list[i % len(nama_wilayah_list)] for i in range(n_samples)],
    'Kode Wilayah': ['CA', 'IL', 'TX', 'CA', 'CA', 'AZ', 'TX', 'FL', 'WA', 'NV'][0:n_samples] if
n_samples <= 10 else ['CA', 'IL', 'TX', 'CA', 'CA', 'AZ', 'TX', 'FL', 'WA', 'NV'] * (n_samples // 10)
+ ['CA'] * (n_samples % 10),
    'Luas Wilayah (mil2)': np.random.randint(15, 4500, size=n_samples),
    'Jumlah Penduduk (jiwa)': np.random.randint(100000, 3000000, size=n_samples),
    'Persen Penduduk 18-34th': np.round(np.random.uniform(16.0, 45.0, size=n_samples), 2),
    'Persen Penduduk >64th': np.round(np.random.uniform(5.0, 25.0, size=n_samples), 2),
    'Jumlah Dokter': np.random.randint(50, 15000, size=n_samples),
    'Jumlah Kejadian Kriminal': np.random.randint(500, 500000, size=n_samples),
    'Persen Lulusan Sarjana/Diploma IV': np.round(np.random.uniform(10.0, 50.0, size=n_samples), 2),
    'Persen Pengangguran': np.round(np.random.uniform(2.5, 15.0, size=n_samples), 2),
    'Pendapatan Perkapita': np.random.randint(9000, 38000, size=n_samples),
    'Klasifikasi Wilayah': np.random.choice(klasifikasi_list, size=n_samples, p=[0.35, 0.25, 0.25,
0.15])
})

print(f"Dataset berhasil dimuat: {df.shape[0]} baris x {df.shape[1]} kolom")
```

OUTPUT EKSEKUSI:

Dataset berhasil dimuat: 440 baris x 13 kolom

2. Melihat Baris Teratas (`df.head()`) dan Terbawah (`df.tail()`)

- `df.head(n)` : Menampilkan \$n\$ baris pertama untuk memverifikasi kesesuaian penamaan kolom dan contoh nilai.
- `df.tail(n)` : Menampilkan \$n\$ baris terakhir.

```
# Melihat 5 baris pertama
print("5 Baris Pertama:")
df.head()
```

OUTPUT EKSEKUSI:

5 Baris Pertama:

OUTPUT EKSEKUSI:

Nomor	Identitas Wilayah	Nama Wilayah	Kode Wilayah	Luas Wilayah (mil2)	\
0	1	Los_Angeles	CA	875	
1	2	Cook	IL	3787	
2	3	Harris	TX	3107	
3	4	San_Diego	CA	481	
4	5	Orange	CA	4441	

	Jumlah Penduduk (jiwa)	Persen Penduduk 18-34th	Persen Penduduk >64th	\
0	1139458	39.19	8.86	
1	2417336	39.93	6.68	
2	2863642	21.41	11.53	
3	1909891	22.84	16.20	
4	2519862	34.38	7.32	

	Jumlah Dokter	Jumlah Kejadian Kriminal	Persen Lulusan Sarjana/Diploma IV	\
0	4305	339615	32.41	
1	14534	356115	40.03	
2	11065	327590	32.32	
3	7447	361633	32.10	
4	1785	84580	13.77	

	Persen Pengangguran	Pendapatan Perkapita	Klasifikasi Wilayah
0	14.12	12664	Midwest
1	2.88	28873	Midwest
2	13.40	22050	South
3	9.09	9680	Midwest
4	10.41	27908	Midwest

3. Memeriksa Metadata & Tipe Data Kolom (`df.info()`)

Metode `df.info()` memberikan ringkasan esensial: 1. Total entri baris (*RangeIndex*). 2. Jumlah kolom beserta nama kolomnya. 3. Nilai yang terisi (*Non-Null Count*) untuk mendeteksi *missing values*. 4. Tipe data masing-masing kolom (*int64*, *float64*, atau *object/string*). 5. Penggunaan memori (*memory usage*).

```
# Memeriksa informasi struktur dataframe
df.info()
```

OUTPUT EKSEKUSI:

```
<class 'pandas.DataFrame'>
RangeIndex: 440 entries, 0 to 439
Data columns (total 13 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Nomor Identitas Wilayah              440 non-null    int64
1   Nama Wilayah                        440 non-null    str
2   Kode Wilayah                        440 non-null    str
3   Luas Wilayah (mil2)                 440 non-null    int32
4   Jumlah Penduduk (jiwa)              440 non-null    int32
5   Persen Penduduk 18-34th             440 non-null    float64
6   Persen Penduduk >64th               440 non-null    float64
7   Jumlah Dokter                       440 non-null    int32
8   Jumlah Kejadian Kriminal            440 non-null    int32
9   Persen Lulusan Sarjana/Diploma IV   440 non-null    float64
10  Persen Pengangguran                 440 non-null    float64
11  Pendapatan Perkapita                440 non-null    int32
12  Klasifikasi Wilayah                 440 non-null    str
dtypes: float64(4), int32(5), int64(1), str(3)
memory usage: 36.2 KB
```

4. Memeriksa Dimensi dan Nama Kolom

```
print("Dimensi Dataframe (Baris, Kolom):", df.shape)
print("\nDaftar Nama Kolom:\n", df.columns.tolist())
```

OUTPUT EKSEKUSI:

```
Dimensi Dataframe (Baris, Kolom): (440, 13)
```

```
Daftar Nama Kolom:
```

```
['Nomor Identitas Wilayah', 'Nama Wilayah', 'Kode Wilayah', 'Luas Wilayah (mil2)', 'Jumlah Penduduk (jiwa)',
'Persen Penduduk 18-34th', 'Persen Penduduk >64th', 'Jumlah Dokter', 'Jumlah Kejadian Kriminal', 'Persen
Lulusan Sarjana/Diploma IV', 'Persen Pengangguran', 'Pendapatan Perkapita', 'Klasifikasi Wilayah']
```

Statistik Deskriptif & Visualisasi Plot EDA

Setelah memahami struktur awal dataset, langkah selanjutnya adalah mengekstrak **ringkasan statistik kuantitatif** (ukuran pemusatan dan penyebaran data) serta visualisasi distribusinya.

1. Menyiapkan Dataset

PYTHON 3

Contoh Kode Praktik

```
import pandas as pd
import numpy as np

# Menyiapkan dataset demografi wilayah (440 baris) yang self-contained & representatif
np.random.seed(42)
n_samples = 440

nama_wilayah_list = [
    'Los_Angeles', 'Cook', 'Harris', 'San_Diego', 'Orange', 'Maricopa', 'Dallas',
    'Miami_Dade', 'King', 'Clark', 'Wayne', 'Tarrant', 'Bexar', 'Santa_Clara',
    'Wayne', 'Alameda', 'Middlesex', 'Hennepin', 'Sacramento', 'Travis', 'Fulton'
]
klasifikasi_list = ['West', 'Midwest', 'South', 'Northeast']

df = pd.DataFrame({
    'Nomor Identitas Wilayah': np.arange(1, n_samples + 1),
    'Nama Wilayah': [nama_wilayah_list[i % len(nama_wilayah_list)] for i in range(n_samples)],
    'Kode Wilayah': ['CA', 'IL', 'TX', 'CA', 'CA', 'AZ', 'TX', 'FL', 'WA', 'NV'][0:n_samples] if
n_samples <= 10 else ['CA', 'IL', 'TX', 'CA', 'CA', 'AZ', 'TX', 'FL', 'WA', 'NV'] * (n_samples // 10)
+ ['CA'] * (n_samples % 10),
    'Luas Wilayah (mil2)': np.random.randint(15, 4500, size=n_samples),
    'Jumlah Penduduk (jiwa)': np.random.randint(100000, 3000000, size=n_samples),
    'Persen Penduduk 18-34th': np.round(np.random.uniform(16.0, 45.0, size=n_samples), 2),
    'Persen Penduduk >64th': np.round(np.random.uniform(5.0, 25.0, size=n_samples), 2),
    'Jumlah Dokter': np.random.randint(50, 15000, size=n_samples),
    'Jumlah Kejadian Kriminal': np.random.randint(500, 500000, size=n_samples),
    'Persen Lulusan Sarjana/Diploma IV': np.round(np.random.uniform(10.0, 50.0, size=n_samples), 2),
    'Persen Pengangguran': np.round(np.random.uniform(2.5, 15.0, size=n_samples), 2),
    'Pendapatan Perkapita': np.random.randint(9000, 38000, size=n_samples),
    'Klasifikasi Wilayah': np.random.choice(klasifikasi_list, size=n_samples, p=[0.35, 0.25, 0.25,
0.15])
})

print(f"Dataset berhasil dimuat: {df.shape[0]} baris x {df.shape[1]} kolom")
```

OUTPUT EKSEKUSI:

Dataset berhasil dimuat: 440 baris x 13 kolom

2. Ringkasan Statistik 5 Angka (`df.describe()`)

Fungsi `df.describe()` menghitung secara otomatis:

- `count` : Jumlah data yang tidak bernilai null.
- `mean` : Nilai rata-rata aritmatika.
- `std` : Standar deviasi (penyebaran data dari rata-rata).
- `min` : Nilai minimum.

- **25%** (Kuartil 1 / Q1), **50%** (Median / Kuartil 2), **75%** (Kuartil 3 / Q3).
- **max** : Nilai maksimum.

PYTHON 3

Contoh Kode Praktik

```
# Menampilkan ringkasan statistik deskriptif untuk seluruh kolom numerik
df.describe()
```

OUTPUT EKSEKUSI:

Nomor	Identitas Wilayah	Luas Wilayah (mil2)	Jumlah Penduduk (jiwa)	\
count	440.000000	440.000000	4.400000e+02	
mean	220.500000	2276.765909	1.536295e+06	
std	127.161315	1243.820185	8.292159e+05	
min	1.000000	19.000000	1.004040e+05	
25%	110.750000	1162.750000	8.414990e+05	
50%	220.500000	2391.500000	1.472964e+06	
75%	330.250000	3283.250000	2.310423e+06	
max	440.000000	4489.000000	2.998073e+06	

	Persen Penduduk 18-34th	Persen Penduduk >64th	Jumlah Dokter	\
count	440.000000	440.000000	440.000000	
mean	30.983818	15.044864	7941.497727	
std	8.300521	5.557366	4148.108149	
min	16.010000	5.020000	66.000000	
25%	23.915000	10.110000	4631.250000	
50%	31.285000	15.495000	8023.000000	
75%	37.995000	19.645000	11327.000000	
max	44.980000	24.870000	14966.000000	

	Jumlah Kejadian Kriminal	Persen Lulusan Sarjana/Diploma IV	\
count	440.000000	440.000000	
mean	234216.295455	29.835750	
std	143461.894459	11.633221	
min	1281.000000	10.010000	
25%	111385.000000	19.852500	
50%	230685.500000	29.520000	
75%	355441.500000	39.870000	
max	499185.000000	49.990000	

	Persen Pengangguran	Pendapatan Perkapita
count	440.000000	440.000000
mean	8.991227	23316.952273
std	3.645562	8516.301587
min	2.510000	9060.000000
25%	5.837500	15393.500000
50%	9.320000	23634.500000
75%	12.162500	30553.000000
max	14.990000	37985.000000

3. Visualisasi Boxplot Sebaran per Wilayah

Boxplot sangat berguna untuk mendeteksi:

- Median garis tengah.
- Rentang interkuartil ($IQR = Q3 - Q1$).
- Titik-titik pencilan (*outliers*).

PYTHON 3

Contoh Kode Praktik

```
import matplotlib.pyplot as plt

plt.figure(figsize=(10, 6))
df.boxplot(column='Pendapatan Perkapita', by='Klasifikasi Wilayah', grid=True)
plt.title('Perbandingan Distribusi Pendapatan Perkapita per Wilayah')
plt.suptitle('') # Hapus default subtitle bawaan pandas
plt.xlabel('Klasifikasi Wilayah')
plt.ylabel('Pendapatan Perkapita (USD)')
plt.show()
```

OUTPUT EKSEKUSI:

<Figure size 1000x600 with 0 Axes>

OUTPUT EKSEKUSI:

<Figure size 640x480 with 1 Axes>

4. Scatter Plot: Korelasi Tingkat Pendidikan vs Pendapatan

PYTHON 3

Contoh Kode Praktik

```
plt.figure(figsize=(9, 5))
df.plot.scatter(
    x='Persen Lulusan Sarjana/Diploma IV',
    y='Pendapatan Perkapita',
    title='Hubungan Antara Tingkat Pendidikan Sarjana & Pendapatan Perkapita',
    c='Persen Pengangguran',
    colormap='viridis',
    figsize=(10, 6),
    sharex=False
)
plt.show()
```

OUTPUT EKSEKUSI:

<Figure size 900x500 with 0 Axes>

OUTPUT EKSEKUSI:

<Figure size 1000x600 with 2 Axes>

Seleksi Kolom & Filtering Data Boolean

Kemampuan memilih (*selecting*) kolom dan menyaring (*filtering*) baris data berdasarkan kriteria tertentu adalah keterampilan paling esensial dalam analisis data sehari-hari.

1. Menyiapkan Dataset

PYTHON 3

Contoh Kode Praktik

```
import pandas as pd
import numpy as np

# Menyiapkan dataset demografi wilayah (440 baris) yang self-contained & representatif
np.random.seed(42)
n_samples = 440

nama_wilayah_list = [
    'Los_Angeles', 'Cook', 'Harris', 'San_Diego', 'Orange', 'Maricopa', 'Dallas',
    'Miami_Dade', 'King', 'Clark', 'Wayne', 'Tarrant', 'Bexar', 'Santa_Clara',
    'Wayne', 'Alameda', 'Middlesex', 'Hennepin', 'Sacramento', 'Travis', 'Fulton'
]
klasifikasi_list = ['West', 'Midwest', 'South', 'Northeast']

df = pd.DataFrame({
    'Nomor Identitas Wilayah': np.arange(1, n_samples + 1),
    'Nama Wilayah': [nama_wilayah_list[i % len(nama_wilayah_list)] for i in range(n_samples)],
    'Kode Wilayah': ['CA', 'IL', 'TX', 'CA', 'CA', 'AZ', 'TX', 'FL', 'WA', 'NV'][0:n_samples] if
n_samples <= 10 else ['CA', 'IL', 'TX', 'CA', 'CA', 'AZ', 'TX', 'FL', 'WA', 'NV'] * (n_samples // 10)
+ ['CA'] * (n_samples % 10),
    'Luas Wilayah (mil2)': np.random.randint(15, 4500, size=n_samples),
    'Jumlah Penduduk (jiwa)': np.random.randint(100000, 3000000, size=n_samples),
    'Persen Penduduk 18-34th': np.round(np.random.uniform(16.0, 45.0, size=n_samples), 2),
    'Persen Penduduk >64th': np.round(np.random.uniform(5.0, 25.0, size=n_samples), 2),
    'Jumlah Dokter': np.random.randint(50, 15000, size=n_samples),
    'Jumlah Kejadian Kriminal': np.random.randint(500, 500000, size=n_samples),
    'Persen Lulusan Sarjana/Diploma IV': np.round(np.random.uniform(10.0, 50.0, size=n_samples), 2),
    'Persen Pengangguran': np.round(np.random.uniform(2.5, 15.0, size=n_samples), 2),
    'Pendapatan Perkapita': np.random.randint(9000, 38000, size=n_samples),
    'Klasifikasi Wilayah': np.random.choice(klasifikasi_list, size=n_samples, p=[0.35, 0.25, 0.25,
0.15])
})

print(f"Dataset berhasil dimuat: {df.shape[0]} baris x {df.shape[1]} kolom")
```

OUTPUT EKSEKUSI:

Dataset berhasil dimuat: 440 baris x 13 kolom

2. Seleksi Kolom (Series vs DataFrame)

- `df['Nama Kolom']` : Mengambil 1 kolom sebagai **Series**.
- `df[['Kolom1', 'Kolom2']]` : Mengambil beberapa kolom sekaligus sebagai **DataFrame**.

PYTHON 3

Contoh Kode Praktik

```
# 1. Mengambil satu kolom (Series)
wilayah_series = df['Nama Wilayah']
print("Tipe 1 Kolom:", type(wilayah_series))
print(wilayah_series.head(3))

# 2. Mengambil subset beberapa kolom (DataFrame)
subset_df = df[['Nama Wilayah', 'Jumlah Penduduk (jiwa)', 'Pendapatan Perkapita']]
print("\nTipe Banyak Kolom:", type(subset_df))
subset_df.head(3)
```

OUTPUT EKSEKUSI:

```
Tipe 1 Kolom: <class 'pandas.Series'>
0    Los_Angeles
1         Cook
2         Harris
Name: Nama Wilayah, dtype: str
```

```
Tipe Banyak Kolom: <class 'pandas.DataFrame'>
```

OUTPUT EKSEKUSI:

	Nama Wilayah	Jumlah Penduduk (jiwa)	Pendapatan Perkapita
0	Los_Angeles	1139458	12664
1	Cook	2417336	28873
2	Harris	2863642	22050

3. Filter Baris Menggunakan Boolean Indexing

Kita membuat kondisi logika Boolean yang menghasilkan `True` atau `False` pada setiap baris.

```
# Filter 1: Wilayah dengan Penduduk > 1.5 Juta Jiwa
populasi_tinggi = df[df['Jumlah Penduduk (jiwa)'] > 1500000]
print(f"Jumlah wilayah berpenduduk > 1.5 juta: {len(populasi_tinggi)}")
populasi_tinggi[['Nama Wilayah', 'Jumlah Penduduk (jiwa)', 'Klasifikasi Wilayah']].head()
```

OUTPUT EKSEKUSI:

Jumlah wilayah berpenduduk > 1.5 juta: 215

OUTPUT EKSEKUSI:

	Nama Wilayah	Jumlah Penduduk (jiwa)	Klasifikasi Wilayah
1	Cook	2417336	Midwest
2	Harris	2863642	South
3	San_Diego	1909891	Midwest
4	Orange	2519862	Midwest
6	Dallas	2486488	South

4. Filter dengan Multi Kondisi (& untuk AND, | untuk OR)

 **Catatan Penting:** Di Pandas, setiap kondisi logika harus diapit tanda kurung (kondisi1) & (kondisi2) .

```
# Filter: Wilayah 'West' DENGAN Pendapatan Perkapita > 25.000
filter_multi = df[(df['Klasifikasi Wilayah'] == 'West') & (df['Pendapatan Perkapita'] > 25000)]
print(f"Ditemukan {len(filter_multi)} wilayah yang memenuhi kriteria:")
filter_multi[['Nama Wilayah', 'Kode Wilayah', 'Pendapatan Perkapita', 'Klasifikasi Wilayah']].head()
```

OUTPUT EKSEKUSI:

Ditemukan 51 wilayah yang memenuhi kriteria:

OUTPUT EKSEKUSI:

	Nama Wilayah	Kode Wilayah	Pendapatan Perkapita	Klasifikasi Wilayah
16	Middlesex	TX	27287	West
21	Los_Angeles	IL	29544	West
36	Alameda	TX	27919	West
39	Sacramento	NV	35400	West
47	Maricopa	FL	28356	West

5. Metode Praktis: `isin()` dan `query()`

- `isin([ ... ])` : Memfilter baris yang nilainya cocok dengan salah satu anggota daftar.
- `query(" ... ")` : Menyaring data dengan sintaksis ekspresi string yang sangat bersih.

```
# Menggunakan isin()
df_west_midwest = df[df['Klasifikasi Wilayah'].isin(['West', 'Midwest'])]
print("Jumlah wilayah West & Midwest:", len(df_west_midwest))

# Menggunakan query()
df_hasil_query = df.query("`Pendapatan Perkapita` > 30000 and `Persen Pengangguran` < 5.0")
print("Wilayah pendapatan tinggi dengan pengangguran rendah:", len(df_hasil_query))
df_hasil_query[['Nama Wilayah', 'Pendapatan Perkapita', 'Persen Pengangguran']]
```

OUTPUT EKSEKUSI:

```
Jumlah wilayah West & Midwest: 249
Wilayah pendapatan tinggi dengan pengangguran rendah: 23
```

OUTPUT EKSEKUSI:

	Nama Wilayah	Pendapatan Perkapita	Persen Pengangguran
15	Alameda	34675	2.53
45	San_Diego	32255	4.31
76	Santa_Clara	36798	4.00
87	San_Diego	33335	4.86
120	Alameda	31724	4.12
135	Clark	31742	2.54
137	Tarrant	33703	4.83
150	San_Diego	31077	4.07
153	Dallas	31544	3.15
157	Wayne	34917	3.57
163	Middlesex	31192	3.75
177	Clark	33729	3.02
213	San_Diego	34135	3.25
240	Clark	33351	3.26
257	Maricopa	33648	4.75
264	Bexar	34640	4.21
278	Maricopa	31520	4.70
372	Alameda	32936	3.10
394	Middlesex	30225	3.15
406	Miami_Dade	34142	4.07
413	Wayne	37985	4.37
417	Sacramento	34812	2.76
438	Sacramento	36080	4.06